

Tech Challenge - Machine Learning

Fase 1 - Tech Challenge A

FIAP - Pós Tech

Inteligência Artificial para DEVs

Rebeca Torrecilhas - RM375231

1 INTRODUÇÃO

Este relatório apresenta o desenvolvimento e os resultados da Fase 1A do projeto de classificação de tumores de câncer de mama utilizando técnicas de Aprendizado de Máquina. O objetivo principal consiste em analisar as características morfológicas dos nódulos mamários e construir modelos preditivos capazes de discriminar de forma precisa entre tumores benignos e malignos, minimizando o risco de falsos negativos.


Os dados utilizados foram disponibilizados através do seguinte [link de acesso](#).

O código foi desenvolvido no Google Colab, o acesso pode ser feito através do seguinte [link de acesso](#).

2 EXPLORAÇÃO DOS DADOS


Para a exploração dos dados foi utilizado o comando `df.shape`, para que fosse possível verificar a dimensionalidade dos dados (linhas e colunas), e foi utilizado o comando `df.info()` para que fosse possível identificar os tipos de dados presentes, que foram eles compostos majoritariamente por variáveis numéricas contínuas flutuantes (float64). As variáveis descrevem características geométricas das células tumorais, e dentre elas está a variável alvo categórica que consiste na variável com o resultado de diagnóstico (Maligno ou Benigno).

O conjunto de dados apresenta uma divisão onde a classe "Benigno" é majoritária em relação à classe "Maligno". A proporção foi verificada via `["diagnosis"].value_counts()`.




Para verificar as Métricas Geométricas foi aplicado o método `df.describe()` para extrair estatísticas como média, desvio padrão, valores mínimos, máximos e quartis.

Para verificar a correlação entre as variáveis, foi avaliado o gráfico de matriz de correlação. Na matriz de correlação, podemos observar uma correlação positiva (tons de vermelho escuro) entre características de tamanho, como radius, perimeter e area.




Verificando a correlação especificamente da classe Diagnóstico com as demais colunas da base de dados, podemos observar no mapa da calor que as variáveis com maior correlação (> 0.70) com a variável diagnóstico (que no caso consiste na mais importante na análise desses dados) são as seguintes:


- concave points_worst (0.79)
- perimeter_worst (0.78)
- Concave_points_mean (0,78)
- radius_worst (0.78)
- perimeter_mean (0.74)
- area_worst (0.73)
- radius_mena (0.73)
- area_mean (0.71)




Observando o gráfico **Boxplot** abaixo, podemos observar que para os casos classificados como malignos, os valores de **radius_mean** tendem a ser maiores quando comparados aos casos benignos. Além disso, podemos perceber uma maior dispersão dos dados na classe maligna, indicando assim uma maior variabilidade desse atributo neste grupo. Nas duas classes (benigna e maligna), existe a presença de outliers, que são representados pelos pontos fora dos limites do boxplot, o que sugere a existência de alguns valores extremos nos dois tipos de diagnósticos. Sendo assim, o atributo **radius_mean** apresenta um bom potencial de discriminação entre os diagnósticos, podendo ser considerado uma variável relevante para modelos de classificação.




Analisando o gráfico abaixo, podemos verificar que a variável **area_mean** é discriminante para o diagnóstico. Os diagnósticos do tipo 1 (Maligno) apresentam áreas médias maiores e com maior variação interna do que os do grupo 0 (Benigno). Os dois grupos também possuem a presença de outliers superiores.




Confirmando o que foi visto no boxplot, podemos observar no gráfico abaixo que a média da área dos tumores classificados como Maligno (aprox. 980) é mais do que o dobro da média dos tumores benignos (aprox. 460).



Analisando as variáveis separadamente, a análise das médias nos permite observar que tumores malignos (1) são bem maiores e mais irregulares do que os benignos (0). A variável **area_mean** é o indicador mais impactante, dobrando de tamanho no diagnóstico maligno, e também há um aumento de 40% em **radius_mean**. A textura (**texture_mean**) também é maior no grupo maligno, embora apresente uma diferença menor (20%). Essas 3 classes de médias são características físicas e visuais dos tumores, e analisando podemos afirmar que são discriminante para a separação das classes.



Analisando o Histograma abaixo, podemos verificar que existe uma maior concentração de tumores na faixa entre 11 e 14, o que sugere que raios menores são mais frequentes.



3 PRÉ-PROCESSAMENTO DE DADOS

Antes de submeter os dados aos algoritmos de Machine Learning, foram adicionados processos de higienização e pré-processamento dos dados. Primeiro foi efetuado o tratamento de Nulos: Executou-se o diagnóstico de completude com `df.isnull().sum()`. Identificou-se que a coluna "Unnamed: 32" continha 100% de valores nulos, sendo assim, a mesma foi eliminada via `df.drop()`.

O próximo passo consistiu na remoção da coluna de identificadores: A coluna "id" foi removida por se tratar de uma chave primária incremental que não agrega valor preditivo ou padrão estatístico ao fenômeno estudado.

O terceiro passo consistiu na codificação da Variável Alvo: A variável categórica **diagnosis** foi mapeada e convertida para o formato numérico binário utilizando dicionário: {"B": 0, "M": 1} (0 para Benigno e 1 para Maligno).

Logo após, foi efetuada a separação de Atributos e Alvo: O conjunto foi dividido em matriz de recursos X (atributos preditores) e vetor de respostas Y (alvo).

O quinto passo foi a divisão em Treino e Teste com Estratificação: A base foi dividida em 80% para treinamento e 20% para testes através do `train_test_split`. Adotou-se a estratégia crítica de amostragem estratificada (`stratify=y`) para garantir que a proporção original de classes (Benignos e. Malignos) fosse fielmente replicada em ambos os subconjuntos, evitando vieses de seleção.

O último passo foi o escalonamento de Recursos (Feature Scaling): Instanciou-se o **StandardScaler** para normalizar as variáveis numéricas, deixando-as na mesma escala (média 0 e desvio padrão 1). O ajuste e transformação (`fit_transform`) foram aplicados estritamente na base de treino, enquanto a base de teste sofreu apenas a transformação (`transform`).

4 MODELAGEM

Os modelos escolhidos foram: Random Forest e Regressão Logística. A regressão logística foi escolhida por ser um modelo que calcula a probabilidade de uma amostra pertencer a uma classe ou outra (Duas opções possíveis, 0 benigno e 1 para maligno). Além disso, a Regressão logística fornece coeficientes diretos, ou seja, pesos, o que auxilia em um contexto médico para o auxílio da tomada de decisão sobre o diagnóstico. Já o Random Forest possui alta performance, utilizado para validar se existem padrões ocultos ou correlações complexas.

5 RANDOM FOREST


Um dos modelos escolhidos foi o algoritmo de classificação Random Forest. Após a inicialização, os dados de treino foram aplicados para o treinamento do modelo. Após o treinamento, os dados de teste foram aplicados para efetuar a predição. A acurácia do modelo,

que consiste na métrica de avaliação de desempenho que representa a proporção total de acertos em relação ao total de casos analisados, foi de **97.37%**. Apesar da acurácia ter um valor excelente, para o contexto é necessário avaliar outras métricas. Utilizando o `classification_report` obtemos os seguintes resultados:

	precision	recall	f1-score	support
Benigno	0.96	1.00	0.98	72
Maligno	1.00	0.93	0.96	42
accuracy			0.97	114
macro avg	0.98	0.96	0.97	114
weighted avg	0.97	0.97	0.97	114

Olhando para o **Recall** (Sensibilidade) da Classe de Maligno (**93%**), que é a métrica mais importante do cenário pois ela mede a capacidade do modelo de encontrar as pacientes doentes, verificamos que temos o valor de 0.93 indica que de 42 pacientes com tumores malignos, o modelo identificou 39 e deixou passar 3 (Falsos Negativos).


Para visualizar e analisar melhor os falsos negativos e os falsos positivos foi utilizada a matriz de confusão.




Analisando a matriz de confusão, podemos observar 3 falsos positivos, quando o modelo classificou como tumor benigno, mas no entanto consistia em 3 tumores malignos.

Aplicando o **Feature Importance**, que consiste na técnica para medir o impacto ou o peso que cada atributo do conjunto de dados tem nas decisões de modelo de Machine Learning calculando quais são mais decisivas para gerar a previsão correta, podemos observar no gráfico abaixo como a variável **area_worst** é o fator mais determinante para o modelo, com mais de 15% de impacto, ou seja, o extremo do nódulo é o principal sinal de malignidade. Nas métricas de contorno e

irregularidade como concave **points_worst** e **perimeter_worst**, somam mais de 23% da tomada de decisão. Ou seja, podemos dizer que o algoritmo priorizou as variáveis de pior cenário (**_worst**) em vez das médias (**_mean**), buscando focar na região mais agressiva da lesão para garantir um diagnóstico preciso.



Aplicando a técnica SHAP (SHapley Additive exPlanations) que consiste em uma técnica que irá medir o impacto individual de cada variável em uma previsão específica. A técnica calcula o quanto cada atributo (como a concavidade de um nódulo) soma ou subtrai na probabilidade do diagnóstico final em relação à média geral. Isso resolve o problema da "caixa-preta" de algoritmos complexos, permitindo que médicos visualizem graficamente, paciente por paciente, os motivos exatos que levaram à suspeita de malignidade.




O gráfico SHAP acima indica que valores altos de características ligadas ao tamanho e à irregularidade do tumor, como já destacado e discutido antes, como concave

points_worst e **area_worst**, possuem forte impacto positivo no SHAP value, empurrando a previsão na direção do diagnóstico Maligno.

Os valores baixos (pontos azuis) dessas mesmas variáveis agrupam-se à esquerda do eixo zero, correlacionando-se diretamente a previsões de tumores benignos. Dessa forma, podemos notar que as variáveis associadas ao erro padrão (**_se**) mostram-se mais concentradas em torno do zero, indicando menor poder de decisão individual. Ou seja, podemos concluir que quanto maiores e mais côncavos forem os tumores, maior será o risco estimado de malignidade.

6 REGRESSÃO LOGÍSTICA

O segundo modelo escolhido foi o de Regressão Logística, que consiste em um algoritmo estatístico de classificação binária que estima a probabilidade de um evento ocorrer (No caso o diagnóstico ser Maligno ou Benigno) com base em variáveis preditoras. O modelo mapeia valores numéricos inseridos em uma curva em formato de "S" (função sigmóide), forçando o resultado a ficar entre 0 e 1. Caso a probabilidade calculada ultrapasse um limite definido (por padrão 0.5), o modelo classifica o caso como positivo, oferecendo alta transparência clínica através de coeficientes que revelam o peso direto de cada atributo no risco final.



A acurácia do modelo também foi de 97.37%. Os resultados obtidos foram os seguintes:


	precision	recall	f1-score	support
Benigno	0.97	0.99	0.98	72
Maligno	0.98	0.95	0.96	42
accuracy			0.97	114
macro avg	0.97	0.97	0.97	114
weighted avg	0.97	0.97	0.97	114

Dado o contexto, A Regressão Logística se mostra como uma opção mais segura, uma vez que o objetivo principal é minimizar os Falsos Negativos. A Regressão Logística identificou 40 dos 42 casos malignos (Recall de


95.24%), enquanto a Random Forest identificou 39. Sendo assim, podemos dizer que a Regressão Logística foi estatisticamente superior no quesito segurança.

Analisando o gráfico de coeficientes abaixo, podemos observar que a irregularidade e a variação estrutural do nódulo são os fatores mais determinantes para apontar a malignidade de um tumor.

A variável **texture_worst** fica em primeiro lugar como o principal indicador de risco, seguida de perto por **radius_se**, evidenciando que uma textura muito áspera e alta oscilação no raio elevam drasticamente a probabilidade de câncer. Podemos notar também que há mais dos atributos do tipo **_worst**, que prova que o modelo prioriza os piores cenários e as regiões mais agressivas da lesão em vez de médias gerais. Como todos os coeficientes são positivos, cada um desses dez fatores atua proporcionalmente, impulsionando o diagnóstico em direção à classe maligna.



Analisando a matriz de confusão abaixo, podemos dizer que para tumores benignos, o algoritmo demonstrou altíssima eficácia ao acertar 71 dos 72 casos reais, resultando em um recall de 99%. No cenário crítico de malignidade, o modelo minimiza riscos graves ao capturar com sucesso 40 dos 42 tumores reais (recall de 95%). A margem de erro limitou-se a apenas 2 falsos negativos e 1 falso positivo.




7 MATRIZ DE CONCORDÂNCIA ENTRE OS MODELOS

A matriz de concordância consiste em uma ferramenta para a validação de robustez. Os dois modelos utilizados empregam técnicas diferentes, a Regressão Logística utilizando a geometria linear e o Random Forest utilizando árvores de decisões, quando os dois modelos chegam na mesma conclusão sobre um caso, a confiabilidade do diagnóstico aumenta. A matriz serve como uma prova de que os modelos encontraram de fato um padrão biológico na base de dados, descartando a utilização de “chute” estatístico.

Os resultados obtidos com a matriz de concordância entre os modelos utilizados podem ser observados no gráfico abaixo.

Matriz de Concordância: Random Forest vs Regressão Logística



Total de casos no teste: 114

Casos onde os modelos discordaram: 4

8 DISCUSSÕES FINAIS

Os modelos podem ser utilizados na prática como uma forma de auxílio na área hospitalar, principalmente como uma forma de triagem. Podem ser utilizados na aplicação da criação de uma lista de prioridades, colocando como preferência de atendimento os diagnósticos em que ambos os modelos classificaram como tumor maligno, seguido pelos diagnósticos em que os modelos não concordam. Os modelos funcionam como uma dupla checagem, otimizando assim os diagnósticos em hospitais. A regressão logística permite com que o médico possa avaliar cada característica do tumor e verificar o peso que essa característica tem em relação ao resultado do diagnóstico. A fila de prioridade possibilita com que a detecção precoce seja feita, o que é fundamental no contexto de tumores.