

Tech Challenge - Machine Learning

Fase 1 - Tech Challenge B

FIAP - Pós Tech

Inteligência Artificial para DEVs

Rebeca Torrecilhas - RM375231

1 INTRODUÇÃO

Este relatório apresenta o desenvolvimento e os resultados da Fase 1B do projeto de classificação e predição de diabetes utilizando técnicas de Aprendizado de Máquina. O objetivo principal consiste em analisar o perfil clínico e os indicadores metabólicos dos pacientes para construir modelos preditivos capazes de discriminar de forma precisa entre indivíduos saudáveis e diabéticos, minimizando o risco de falsos negativos.


Os dados utilizados foram disponibilizados através do seguinte [link de acesso](#).

O código foi desenvolvido no Google Colab, o acesso pode ser feito através do seguinte [link de acesso](#).

2 EXPLORAÇÃO DOS DADOS


Para a exploração dos dados foi utilizado o comando `df.shape`, para que fosse possível verificar a dimensionalidade dos dados (linhas e colunas), e foi utilizado o comando `df.info()` para que fosse possível identificar os tipos de dados presentes, que foram eles compostos majoritariamente por variáveis numéricas (inteiros e flutuantes). As variáveis descrevem características clínicas e indicadores metabólicos dos pacientes, e dentre elas está a variável alvo categórica que consiste na variável com o resultado de diagnóstico (Com Diabetes ou Sem Diabetes).

O conjunto de dados apresenta uma divisão onde a classe "Sem Diabetes" é majoritária em relação à classe "Com Diabetes". A proporção foi verificada via `df["Outcome"].value_counts()`.



Para verificar as Métricas Clínicas e Metabólicas foi aplicado o método `df.describe()` para extrair estatísticas como média, desvio padrão, valores mínimos, máximos e quartis.

Para verificar a correlação entre as variáveis, foi avaliado o gráfico de matriz de correlação. Na matriz de correlação, podemos observar uma correlação positiva moderada (tons beges e laranjas claros) entre a variável alvo **Outcome** e a **Glucose** (0.47), além de relações fisiológicas esperadas, como entre **Age** e **Pregnancies** (0.54) e entre **Insulin** e **SkinThickness** (0.44). Ou seja, observando a matriz de correlação podemos verificar que a variável alvo possui uma correlação mais forte com a variável **GLUCOSE**, a segunda maior correlação é o **BMI**, que consiste no índice de Massa Corporal.



Analisando separadamente a correlação com a variável de resultado outcome, podemos verificar que visualmente **GLUCOSE** é de fato a variável com maior associação linear com o diagnóstico seguido do **BMI**. Podemos observar que não há características analisadas com correlação inversa (valores negativos), o que significa que o aumento de qualquer um dos fatores está relacionado com um risco maior de diabetes.

Verificando a correlação especificamente da classe Diagnóstico (Outcome) com as demais colunas da

base de dados, podemos observar no mapa de calor que não existem correlações fortes (> 0.70).


As variáveis com maior correlação positiva linear moderada e fraca com a variável diagnóstico são as seguintes:

Glucose (0.47)

BMI (0.29)


Age (0.24)

Pregnancies (0.22)




Observando o gráfico **Boxplot** abaixo, podemos observar que para os casos classificados como Diabético, os valores de Glicose (mg/dL) tendem a ser maiores quando comparados aos casos Não Diabético. Além disso, podemos perceber uma maior dispersão dos dados na classe Diabético, o que aponta para uma maior variabilidade desse atributo neste grupo.

Nas duas classes (Não Diabético e Diabético), existe a presença de outliers, que são representados pelos pontos fora dos limites do **boxplot**. O atributo Glicose apresenta um bom potencial de discriminação entre os diagnósticos, visto que as medianas e as caixas centrais estão bem separadas, podendo ser considerado uma variável altamente relevante para modelos de classificação de diabetes.



Analisando os dados e os gráficos, podemos

perceber que os pacientes diagnosticados com diabetes apresentam níveis de glicose significativamente mais altos, com a mediana em torno de 140 mg/dL contra 108 mg/dL dos não diabéticos. O grupo não diabético é mais concentrado, mas possui diversos outliers com glicose alta, indicando pessoas em estado de alerta (pré-diabetes) que ainda não desenvolveram a doença.



Observando os histogramas acima gerados, podemos entender os seguintes pontos:

Existe uma assimetria à direita, ou seja as variáveis Age, Pregnancies, **DiabetesPedigreeFunction** e **Insulin** apresentam forte assimetria positiva, o que pode estar indicando que a maior parte da população do estudo é jovem, teve poucas gestações e possui histórico genético/nível de insulina concentrado em valores baixos. Podemos perceber que existe um desbalanceamento de classes, pois a barra do valor 0 é significativamente maior do que a do valor 1, evidenciando o desbalanceamento onde aproximadamente 65% da base representa indivíduos não diabéticos.

3 PRÉ-PROCESSAMENTO DE DADOS

Antes de submeter os dados aos algoritmos de Machine Learning, foram adicionados processos de higienização e pré-processamento dos dados. Primeiro foi efetuado o diagnóstico de completude com `df.isnull().sum()`. Identificou-se que não havia valores nulos na estrutura do **DataFrame**, não sendo necessário o descarte de linhas ou colunas por esse motivo. O próximo passo consistiu na identificação de tipos de dados: A verificação mostrou que a base é composta inteiramente por variáveis numéricas (int64 e float64), portanto, nenhuma codificação de variáveis categóricas ou mapeamento por dicionário precisou ser realizada na variável alvo Outcome ou nos preditores. O terceiro passo consistiu no tratamento de valores zerados inválidos (Imputação): Identificou-se que as colunas Glucose, **BloodPressure**, **SkinThickness**, **Insulin** e **BMI** continham valores iguais a zero, o que representa uma inconsistência biológica. Esses valores foram substituídos por `np.nan` e corrigidos através do **SimpleImputer** utilizando a estratégia da **mediana**. Logo após, foi efetuada a separação de Atributos e Alvo: O conjunto foi dividido em matriz de recursos X (atributos preditores) e vetor de respostas y (alvo correspondente à coluna Outcome). O quinto passo foi a divisão em Treino e Teste com Estratificação: A base foi dividida em 80% para treinamento e 20% para testes através do `train_test_split`. Adotou-se a

estratégia crítica de amostragem estratificada (**stratify=y**) para garantir que a proporção original de classes (Sem Diabetes e Com Diabetes) fosse fielmente replicada em ambos os subconjuntos, evitando vieses de seleção. O último passo foi o ajuste do Imputer nos subconjuntos: O ajuste e a transformação (**fit_transform**) foram aplicados estritamente na base de treino para calcular as medianas, enquanto a base de teste sofreu apenas a transformação (**transform**), impedindo o vazamento de informações entre as bases.

4 MODELAGEM

Os modelos escolhidos foram: Random Forest e Regressão Logística. A regressão logística foi escolhida por ser um modelo que calcula a probabilidade de uma amostra pertencer a uma classe ou outra (Duas opções possíveis, 0 para sem diabetes e 1 para com diabetes). Além disso, a Regressão Logística fornece coeficientes diretos, ou seja, pesos, o que auxilia em um contexto médico para o auxílio da tomada de decisão sobre o diagnóstico. Já o Random Forest possui alta performance, utilizado para validar se existem padrões ocultos ou correlações complexas.


5 RANDOM FOREST

Um dos modelos escolhidos foi o algoritmo de classificação Random Forest. Após a inicialização, os dados de treino foram aplicados para o treinamento do modelo. Após o treinamento, os dados de teste foram aplicados para efetuar a predição.


A acurácia do modelo, que consiste na métrica de avaliação de desempenho que representa a proporção total de acertos em relação ao total de casos analisados, foi de 74.03%. Apesar da acurácia ter um valor razoável, para o contexto é necessário avaliar outras métricas. Utilizando o **classification_report** obtemos os seguintes resultados:

	precision	recall	f1-score	support
Sem Diabetes	0.82	0.72	0.76	99
Com Diabetes	0.58	0.71	0.64	55
accuracy			0.71	154
macro avg	0.70	0.71	0.70	154
weighted avg	0.73	0.71	0.72	154

Olhando para o Recall (Sensibilidade) da Classe Com Diabetes (71%), que é a métrica mais importante do cenário, pois ela mede a capacidade do modelo de encontrar os pacientes doentes, verificamos que o valor de 0.71 indica que de 55 pacientes com diabetes, o modelo identificou corretamente 39 e deixou passar 16 (Falsos Negativos). Para visualizar e analisar melhor os falsos negativos e os falsos positivos, foi utilizada a matriz de confusão.



Analisando a matriz de confusão, podemos observar 20 falsos negativos, quando o modelo classificou como não diabético, mas no entanto consistia em 20 pacientes diabéticos. Também observamos 20 falsos positivos, onde indivíduos sem a condição foram classificados incorretamente como diabéticos.




Aplicando o Feature Importance, que consiste na técnica para medir o impacto ou o peso que cada atributo do conjunto de dados tem nas decisões do modelo de Machine Learning calculando quais são mais decisivas para gerar a previsão correta, podemos observar no gráfico abaixo como a variável Glucose é o fator mais determinante para o modelo, com pouco mais de 25% de impacto, ou seja, o nível de glicose no sangue é o principal sinal para o diagnóstico. Na sequência, as métricas de BMI (Índice de Massa Corporal) e Age (Idade) somam juntas mais de 30% da tomada de decisão. Ou seja, podemos dizer que o algoritmo priorizou as variáveis metabólicas e demográficas principais em detrimento de variáveis como Pregnancies (Gestações), buscando focar nos indicadores mais críticos do organismo para tentar garantir um diagnóstico preciso.

Para otimizar o desempenho do modelo, foi realizada uma seleção de atributos removendo as colunas menos relevantes (**SkinThickness** e **Pregnancies**). O algoritmo Random Forest foi reorientado para focar estritamente nas 6 variáveis com maior poder preditivo e impacto no **SHAP**.

Novo Relatório de Classificação:

	precision	recall	f1-score	support
Sem Diabetes	0.82	0.72	0.76	99
Com Diabetes	0.58	0.71	0.64	55
accuracy			0.71	154
macro avg	0.70	0.71	0.70	154
weighted avg	0.73	0.71	0.72	154

Após o novo treinamento dos dados filtrados, o modelo demonstrou um ganho de eficiência ao descartar ruídos estatísticos da base de dados. Como resultado direto dessa simplificação estrutural, a acurácia geral do diagnóstico se consolidou em 71.43% no conjunto de testes, trazendo um equilíbrio muito maior no cenário clínico ao elevar o Recall (sensibilidade) de pacientes doentes para 71%. Isso comprova que menos atributos, desde que altamente informativos, geram um modelo de classificação mais assertivo e focado na real identificação do público-alvo.



Aplicando a técnica **SHAP** (SHapley Additive exPlanations) que consiste em uma técnica que irá medir o impacto individual de cada variável em uma previsão específica. A técnica calcula o quanto cada atributo (como o nível de glicose) soma ou subtrai na probabilidade do diagnóstico final em relação à média geral. Isso resolve o problema da "caixa-preta" de algoritmos complexos, permitindo que médicos visualizem graficamente, paciente por paciente, os motivos exatos que levaram à suspeita de diabetes.


O gráfico **SHAP** acima indica que valores altos de características ligadas aos índices metabólicos, como já destacado e discutido antes, como **Glucose** e **BMI**, possuem forte impacto positivo no **SHAP** value (pontos vermelhos concentrados à direita), empurrando a previsão na direção do diagnóstico Diabético.

Os valores baixos (pontos azuis) dessas mesmas variáveis agrupam-se à esquerda do eixo zero, correlacionando-se diretamente a previsões de indivíduos não diabéticos. Dessa forma, podemos notar que as variáveis como **SkinThickness** (Espessura da Pele) e **BloodPressure** (Pressão Arterial) mostram-se mais concentradas em torno do zero, indicando menor poder de decisão individual ou impacto quase nulo na decisão

do algoritmo. Ou seja, podemos concluir que quanto maiores forem os níveis de glicose e o IMC, maior será o risco estimado de diabetes.

6 REGRESSÃO LOGÍSTICA

O segundo modelo escolhido foi o de Regressão Logística, que consiste em um algoritmo estatístico de classificação binária que estima a probabilidade de um evento ocorrer (No caso o diagnóstico ser Com Diabetes ou Sem Diabetes) com base em variáveis preditoras. O modelo mapeia valores numéricos inseridos em uma curva em formato de "S" (função sigmóide), forçando o resultado a ficar entre 0 e 1. Caso a probabilidade calculada ultrapasse um limite definido (por padrão 0.5), o modelo classifica o caso como positivo, oferecendo alta transparência clínica através de coeficientes que revelam o peso direto de cada atributo no risco final.



O gráfico da curva sigmóide mostra que a Regressão Logística calcula a probabilidade mapeando o score de risco de cada paciente de forma contínua. Os pontos azuis (saudáveis) predominam no lado esquerdo com probabilidades baixas, enquanto os pontos vermelhos (diabéticos) se concentram à direita acima do limiar de 0.50. Mas conseguimos verificar que há uma visível sobreposição de cores perto do centro do gráfico, indicando os erros de classificação (falsos positivos e falsos negativos) que limitam a acurácia do modelo linear. Essa mistura ocorre principalmente porque as variáveis mais importantes reveladas no Random Forest, como **Glucose** e **BMI**, possuem relações não-lineares complexas na zona de transição da doença.

A acurácia do modelo foi de 71.43% . Os resultados obtidos foram os seguintes:


	precision	recall	f1-score	support
Sem Diabetes	0.82	0.72	0.76	99
Com Diabetes	0.58	0.71	0.64	55
accuracy			0.71	154
macro avg	0.70	0.71	0.70	154
weighted avg	0.73	0.71	0.72	154

Dado o contexto, a Regressão Logística se mostra como uma opção mais segura, uma vez que o objetivo principal é minimizar os Falsos Negativos. A Regressão Logística identificou 39 dos 55 casos de diabetes (Recall de 71%), o que garante que o modelo capture a maioria dos pacientes doentes no cenário clínico. Sendo assim, o


algoritmo demonstra um bom equilíbrio na identificação da condição médica prioritária.

Analisando o gráfico de coeficientes abaixo, podemos observar que o histórico familiar e a composição corporal são os fatores mais determinantes para apontar a presença de diabetes.

A variável **DiabetesPedigreeFunction** fica em primeiro lugar como o principal indicador de risco, seguida de perto por BMI (Índice de Massa Corporal) e Age (Idade), evidenciando que uma forte predisposição genética, o alto índice de massa corporal e o avanço da idade elevam drasticamente a probabilidade da condição. Diferente de outros cenários onde múltiplos fatores possuem pesos parecidos, aqui a função de pedigree genético se destaca isolada como o principal impulsionador do diagnóstico em direção à classe positiva.



O gráfico de coeficientes nos mostra que a Regressão Logística considera o histórico genético (**DiabetesPedigreeFunction**) e o BMI como os fatores matemáticos de maior peso para empurrar o diagnóstico para positivo. Diferente do Random Forest (onde a glicose dominava), o modelo linear foca na escala das variáveis, mantendo a **Insulin** neutra e atribuindo um peso sutilmente negativo à **BloodPressure**. Podemos concluir nesse caso que como modelos lineares e baseados em árvores interpretam o risco clínico sob perspectivas matemáticas completamente diferentes.



Analisando a matriz de confusão acima podemos observar que o modelo cometeu 44 erros no total: 28 Falsos Positivos, ou seja, o modelo alarmou que 28 pessoas saudáveis tinham diabetes. O que não é o ideal, uma vez que em um cenário médico, isso gera custos com exames adicionais desnecessários e estresse para o paciente. O modelo também relatou 16 Falsos Negativos, que é o erro mais perigoso. O modelo disse que 16 pessoas eram saudáveis, mas elas realmente tinham

diabetes. O que não é ideal, uma vez que esses pacientes voltariam para casa sem o tratamento adequado.

7 MATRIZ DE CONCORDÂNCIA ENTRE OS MODELOS


A matriz de concordância consiste em uma ferramenta essencial para a validação de robustez do pipeline preditivo. Os dois modelos avaliados empregam fundamentos matemáticos completamente distintos: a Regressão Logística baseia-se na geometria linear e em fronteiras de decisão contínuas (mapeadas pela função sigmoide), enquanto o Random Forest atua por meio de um comitê probabilístico de árvores de decisão.

Quando ambos os algoritmos chegam à mesma conclusão sobre uma amostra, a confiabilidade do diagnóstico clínico aumenta significativamente. Essa convergência serve como uma evidência sólida de que os modelos detectaram padrões metabólicos e fisiológicos reais na base de dados, mitigando o risco de correlações espúrias ou "chutes" estatísticos.

Os resultados obtidos com a matriz de concordância entre os modelos utilizados podem ser observados no gráfico abaixo:

- I. Concordância em Casos Negativos:** Os modelos convergem perfeitamente ao classificar 84 indivíduos conjuntamente como Sem Diabetes.
- II. Concordância em Casos Positivos:** Ambos os algoritmos concordaram e identificaram 52 pacientes com Diabetes.
- III. Divergências de Fronteira:** Registrou-se uma discordância em apenas 18 casos no total (onde 15 foram classificados como diabéticos apenas pela Regressão Logística e 3 apenas pelo Random Forest), evidenciando o alto grau de alinhamento e consistência preditiva entre as duas abordagens.

Matriz de Concordância: Random Forest vs Regressão Logística



8 DISCUSSÕES FINAIS

Os modelos podem ser utilizados na prática como uma forma de auxílio na área clínica e hospitalar, principalmente como uma ferramenta de triagem. Podem ser aplicados na criação de uma lista de prioridades de atendimento, colocando como preferência de consulta ou exames aprofundados os pacientes em que ambos os modelos classificaram o diagnóstico como positivo para diabetes, seguido pelos casos em que os modelos não concordam entre si.

Os modelos funcionam como um sistema de dupla checagem, otimizando e agilizando os diagnósticos nos serviços de saúde. A Regressão Logística permite com que o médico possa avaliar cada característica clínica e metabólica do paciente e verificar o peso direto que esse atributo exerce em relação ao risco final estimado. A fila de prioridade possibilita com que a detecção precoce seja feita, o que é fundamental no contexto do diabetes para evitar complicações crônicas e iniciar o manejo adequado o quanto antes.